

TP – Analyse des performances et de l’assiduité des étudiants

Objectif

L’objectif de ce TP est d’analyser les performances et l’assiduité des étudiants à partir d’un dataset (`studentData.xls`), puis de regrouper les étudiants selon leurs profils à l’aide de méthodes de clustering. Cette analyse permet d’identifier différents types d’étudiants et de proposer des stratégies pédagogiques adaptées.

Étapes du TP

1. Agréger les données par étudiant

- Regrouper le dataset **par étudiant** (`Name`).
- Pour chaque étudiant, calculer :
 - La **moyenne des notes** (`Mark`)
 - La **moyenne de présence** (`Attended`)
- Cette étape permet de résumer les performances et l’assiduité de chaque étudiant sur tous les cours suivis.

Résultat attendu : un tableau avec une ligne par étudiant, contenant sa moyenne de notes et sa moyenne d’assiduité.

2. Préparer les données pour le clustering

- Sélectionner les variables pertinentes : **moyenne des notes** et **moyenne d’assiduité**.
- **Standardiser** ces variables pour que l’échelle ne biaise pas le clustering.

3. Clustering avec K-Means

- Appliquer la méthode **K-Means** pour regrouper les étudiants en différents clusters.
- Choisir un nombre de clusters (par exemple 3) pour identifier différents profils :
 1. Étudiants très assidus et performants
 2. Étudiants moins assidus mais performants
 3. Étudiants moins assidus et moins performants
- Visualiser les résultats avec un **nuage de points**, avec une couleur différente pour chaque cluster et possibilité d’annoter les étudiants.

4. Clustering hiérarchique

- Appliquer un **clustering hiérarchique** sur les mêmes variables standardisées.
- Tester différentes méthodes de liaison : simple, moyenne, complète.
- Représenter les résultats sous forme de **dendrogramme**, permettant de visualiser la hiérarchie des regroupements et les distances entre étudiants.

Analyse et interprétation

1. Résultats du regroupement par étudiant

- Les moyennes de notes et de présence permettent de résumer rapidement la performance et l'assiduité de chaque étudiant.

2. Analyse des clusters (K-Means)

- Trois profils d'étudiants peuvent être identifiés :
 1. **Très assidus et performants**
 2. **Moins assidus mais performants**
 3. **Moins assidus et moins performants**
- Le nuage de points montre la séparation entre ces groupes, ce qui facilite l'identification des étudiants nécessitant un suivi particulier.

3. Analyse du clustering hiérarchique

- Les dendrogrammes confirment la structure des clusters.
- Cette méthode permet également de déterminer le **nombre optimal de clusters**.

4. Interprétation pédagogique

- Les étudiants très assidus ont souvent de meilleures notes, mais certaines exceptions existent.
- Les clusters permettent :
 - Détecter les étudiants nécessitant un suivi spécifique
 - Identifier les étudiants pouvant soutenir leurs pairs
 - Adapter les méthodes pédagogiques selon le profil des étudiants

Questions supplémentaires

Analyse descriptive

1. Quel étudiant a obtenu la **meilleure moyenne de notes** ?
2. Quel étudiant a eu la **plus grande assiduité** ?

3. Quel étudiant a la **moyenne la plus faible** et la **présence la plus faible** ?
4. Calculer et commenter la **corrélation** entre la moyenne de notes et la moyenne de présence.

Clustering approfondi

5. Tester différents nombres de clusters pour K-Means (2, 3, 4, 5) et comparer les résultats.
6. Calculer le **score silhouette** pour chaque nombre de clusters et déterminer le nombre optimal de clusters.
7. Identifier les étudiants proches de la frontière entre deux clusters et analyser leur profil.

Visualisation et interprétation

8. Représenter les clusters avec différentes tailles ou couleurs selon la moyenne de notes.
9. Ajouter les **centroïdes** des clusters sur le graphique.
10. Comparer les clusters obtenus par K-Means avec ceux du clustering hiérarchique.

Analyse pédagogique

11. Proposer des stratégies de suivi adaptées pour chaque cluster.
12. Identifier les étudiants pouvant **servir de tuteurs** pour leurs pairs.
13. Quels indicateurs supplémentaires (projets réalisés, participation, retards, etc.) pourraient enrichir l'analyse des profils ?